



Universidade Estadual de Campinas

ME731 - Métodos em Análise Multivariada

Modelo de Mistura Gaussiana na Análise dos Gastos com Saúde dos Países

Aluno:

Cauã Pereira Masseu 204238

Campinas - SP

26 de setembro de 2024

1 Introdução

A saúde é fundamental para o desenvolvimento das pessoas, tanto biologicamente quanto socialmente, sendo uma das coisas mais valiosa que uma pessoa pode ter. Assim, o quanto um país investe na área da saúde reflete diretamente no compromisso de melhorar a qualidade de vida de sua população, o que torna a coleta e análise de dados relacionados a investimentos nessa área interessante para auxiliar na melhoria.

A clusterização em variáveis relacionadas a despesas na área da saúde de um país nos ajuda a entender padrãos não visíveis, além de realizar o agrupamento entre países que possuem características semelhantes, assim, auxiliando a tomar decisões sólidas, otimizando tempo e recurso investido. Também nos permite identificar as desigualdades existentes entre os sistema de saúde dos países, demonstrando a necessidades de saúde das populações de cada país. Portanto, entender como o Brasil se posiciona em relação a outros países é crucial para visualizar semelhanças e diferenças, orientando estratégias para a melhoria.

Assim, para realizar o estudo foi utilizado o banco de dados "Health systems" de "World Bank Group", referente ao ano de 2021, no qual contém 167 observações com 6 variáveis, dentre as quais são:

- Country: País ao qual as variáveis foram medidas
- Curr_Exp: Nível de despesas atuais com saúde expresso como uma porcentagem do PIB.
- Gov_Exp: Participação das despesas atuais com saúde financiadas por fontes públicas internas. (% de Curr_Exp)
- Out_Exp: Participação dos pagamentos diretos das famílias nas despesas atuais totais com saúde. (% de Curr_Exp)
- Exp_Per_Capita: Despesa atual na saúde per capita em doláres (USD).
- Ext_Health_Exp: Participação das despesas atuais com saúde financiadas por fontes externas. (% de Curr_Exp)

Obs: Importante ressaltar que a demais variáveis que estavam presentes no banco de dados original, além de possuir muitos valores faltantes, não foram medidas no mesmo ano, o que pode prejudicar significativamente a análise estatística.

2 Metodologia

2.1 Análise Exploratória

Gráficos de dados multivariados são fundamentais, pois fornecem uma intuição sobre a estrutura dos dados, sugerindo a presença de clusters e indicando a técnica de agrupamento mais adequada. Histogramas das variáveis podem ser utilizados para verificar a quantidade de modas, sinalizando a existência de diferentes clusters. Além disso, "scatterplots" são uma das principais técnicas para visualizar as variáveis em pares, permitindo analisar a estrutura dos dados e identificar possíveis clusters. Os gráficos também ajudam a detectar outliers, que podem impactar significativamente a clusterização, estes, que exigem uma atenção especial. Entretanto, alguns clusters podem não ser captados utilizando apenas essas técnicas.

2.2 Modelo de Mistura Gaussiana (GMM)

O Modelo de Mistura Gaussiana (GMM) é uma técnica estatística de agrupamento no qual assume que os dados podem ser representados como uma combinação de várias distribuições gaussianas multivariadas. Cada componente gaussiana é caracterizada por sua média e matriz de variância-covariância, o que permite modelar dados que apresentam subgrupos ou clusters diferentes, podendo capturar a complexidade e a variabilidade dos dados de forma eficaz.

2.2.1 Densidade de mistura finita

Suponha que os dados consistem de n observações multivariadas, $x_1, ..., x_n$ cada um de dimensão p, ou seja, $x_i = (x_{i1}, ..., x_{ip})$. Um modelo de mistura finita representa a distribuição de probabilidade ou a função de densidade de uma observação multivariada x_i como uma mistura finita ou média ponderada de c funções de densidade de probabilidade, chamadas de componentes da mistura. Densidades de mistura finitas possuem a seguinte forma:

$$f(x_i, p, \theta) = \sum_{j=1}^{c} p_j g_j(x_i; \theta_j) \tag{1}$$

onde $\theta' = (\theta'_1, \theta'_2, ...\theta'_c)$ e $p = (p_1, p_2, \ldots, p_c)$ com p_j sendo a proporção de mistura, ou seja, a probabilidade de uma observação pertencer a j-ésima componente, e g_j sendo a componente de densidade, com a densidade de g_j sendo caracterizada por θ_j. As proporções de mistura são não negativas tais que $\sum_{j=1}^{c} p_j = 1$. O número de componentes que formam a mistura, ou seja, o número de clusters, é c. Misturas finitas fornecem modelos adequados para análise de clusters se assumirmos que cada grupo de observações em um conjunto de dados suspeito de conter clusters vem de uma população com uma

distribuição de probabilidade diferente. Esta última pode pertencer à mesma família de distribuição, mas diferir nos valores dos parâmetros da distribuição, o que acontece na maioria dos casos.

Consideraremos, no modelo de mistura gaussiana, que g_j segue uma densidade normal multivariada de dimensão p, parametrizada pelo vetor médio μ_j e pela matriz de covariância Σ_j, ou seja, $\theta = (\mu_j, \Sigma_j)$, possuindo a seguinte forma:

$$g_j(x_i|\mu_j, \Sigma_j) = \frac{1}{(2\pi)^{p/2}|\Sigma|^{1/2}} \exp\left\{-\frac{1}{2}(x_i - \mu_j)'\Sigma_j^{-1}(x_i - \mu_j)\right\}. \tag{2}$$

Entretanto, outras densidades podem ser consideradas quando se utiliza modelo de mistura. Por exemplo, se os dados apresentarem distribuições assimétricas, GMMs podem não ser a melhor escolha, pois as gaussianas são simétricas por definição, assim, modelos alternativos, como misturas de distribuições não gaussianas, podem ser mais adequados.

2.2.2 Estimação de máxima verossimilhança de mistura de densidade da normal multivariada utilizando algoritmo EM

No caso de densidades de misturas finitas, a função de verossimilhança geralmente é muito complicada de achar seu ponto máximo com a maneira usual. Portanto, os estimadores de máxima verossimilhança devem ser calculados de outra maneira, com algumas das alternativas envolvendo estimação bayesiana via Monte Carlo Markov Chain (MCMC). Entretanto, a maneira alternativa mais utilizada é o algoritmo **EM**, descrito em [1], no qual é um método bastante utilizado para máxima verossimilhança em problemas nos quais os dados podem ser vistos como consistindo de n observações multivariadas (x_i, z_i), nas quais x_i é observado e z_i é não observado. Se os (x_i, z_i) são independentes e identicamente distribuídos (iid) de acordo com uma distribuição de probabilidade g com parâmetros θ, então a verossimilhança dos dados completos é:

$$L_C(x, z|\theta) = \prod_{i=1}^{n} f(x_i, z_i|\theta) \tag{3}$$

onde $x = (x_1, \ldots, x_n)$ e $z = (z_1, \ldots, z_n)$. Assim, a verossimilhança dos dados observados, $L_O(x|\theta)$, pode ser obtida integrando os dados não observados z da verossimilhança dos dados completos.

$$L_O(x|\theta) = \int L_C(x, z|\theta)\, dz. \tag{4}$$

O estimador de máxima verossimilhança de θ com base nos dados observados maximiza $L_O(x|\theta)$ em relação a θ. A verossimilhança dos dados observados, também chamada de verossimilhança de mistura, pode ser escrita como

$$L_O(x|\theta) = \prod_{i=1}^{n} \sum_{j=1}^{c} p_j g_j(x_i|\theta_j) \tag{5}$$

O algoritmo EM alterna entre dois passos. O primeiro é o passo "E", no qual calcula-se a expectativa do logaritmo da verossimilhança completa, dado os dados observados e os parâmetros estimados da iteração anterior. Especificamente, calcula-se o seguinte:

$$E(\log(L_C(\mu^{(k)}, \Sigma^{(k)}))|x, \mu^{(k-1)}, \Sigma^{(k-1)}) \tag{6}$$

O segundo é o passo "M"(passo de maximização), no qual os parâmetros que maximizam a log-verossimilhança esperada do passo "E" são determinados. São necessários valores iniciais para o algoritmo EM, e existem algumas técnicas adequadas para obtê-los. Além disso, sob algumas condições de regularidade bastante brandas, pode-se demonstrar que o EM converge para um máximo local da verossimilhança dos dados observados; mais detalhes em [2].

Aplicando para modelos de mistura, a porção não observada dos dados, z, envolve quantidades que são introduzidas para reformular o problema para o EM. Assim, os "dados completos" são considerados como (x_i, z_i), onde $z_i = (z_{i,1}, \ldots, z_{i,c})$ é a porção não observada dos dados, com

$$z_{i,j} = \begin{cases} 1, & \text{se } x_i \text{ pertence ao grupo j} \\ 0, & \text{caso contrário} \end{cases}$$

Assumimos que os z_i são independentes e identicamente distribuídos, cada um de acordo com uma distribuição multinomial de c categorias com probabilidades $p_1, \ldots, p_c$. Também assumimos que a densidade de uma observação x_i dada z_i é dada por $\sum_{j=1}^{c} g_j(x_i|\theta_j)^{z_{i,j}}$. Assim, a log-verossimilhança dos dados completos resultante é

$$l_C(\theta_j, p_j, z_{i,j}|x) = \prod_{i=1}^{n} \sum_{j=1}^{c} z_{i,j} \log(p_j g_j(x_i|\theta_j)) \tag{7}$$

Portanto, o passo E da k-ésima iteração do algoritmo EM para modelos de mistura é dado por

$$\hat{z}_{i,j}^{(k)} = \frac{\hat{p}_g^{(k-1)} g_j(x_i|\hat{\theta}_j^{(k-1)})}{\sum_{h=1}^{c} \hat{p}_h^{(k-1)} g_h(y_i|\hat{\theta}_h^{(k-1)})}, \tag{8}$$

onde $\hat{p}_j^{(k)}$ é o valor de p_j após a k-ésima iteração do EM. O passo M envolve a maximização da equação (7) em relação a p_j e θ_j com $z_{i,j}$ fixado nos valores computados no passo E, ou seja, $\hat{z}_{i,j}$.

A quantidade $\hat{z}_{i,j}^{(k)} = E[z_{i,j}|x_i, \theta_1, \ldots, \theta_c]$ é a expectativa condicional de $z_{i,g}$ dada os

valores dos parâmetros na $(k-1)$-ésima iteração e os dados observados x. O valor $\hat{z}_{i,g}$ de $z_{i,g}$ é a probabilidade condicional estimada de que a observação i pertence ao grupo g.

Portanto, para mistura de normais multivariadas, o passo E é dado por (8) com g_j conforme definido em (2), independentemente da parametrização. Para o passo M, as estimativas das médias e probabilidades têm expressões fechadas simples envolvendo os dados e $\hat{z}_{i,j}^{(k)}$ do passo E, assim:

$$\hat{n}_j^{(k-1)} = \sum_{i=1}^{n} \hat{z}_{i,j}^{(k-1)} \quad \hat{p}_j^{(k)} = \frac{\hat{n}_j^{(k-1)}}{n} \quad \hat{\mu}_j^{(k)} = \frac{\sum_{i=1}^{n} \hat{z}_{i,j}^{(k-1)} x_i}{\hat{n}_j^{(k-1)}}$$

A computação da estimativa de covariância $\hat{\Sigma}_j^{(k)}$ depende de sua parametrização. Entretanto, para o modelo mais geral "VVV", onde nenhuma restrição é imposta aos volumes, formas e orientações das matrizes de covariância da mistura, temos:

$$\hat{\Sigma}_j^{(k)} = \frac{1}{\hat{n}_j^{(k-1)}} \sum_{i=1}^{n} \hat{z}_{i,j}^{(k-1)} (y_i - \hat{\mu}_j^{(k)})(y_i - \hat{\mu}_j^{(k)})'$$

A convergência do algoritmo EM para um máximo local da função de log-verossimilhança pode ser avaliada de várias maneiras. Em essência, essas consistem em verificar se o algoritmo tem se movido lentamente nas últimas iterações. Um critério bastante viável é que a log-verossimilhança tenha mudado muito pouco, geralmente próximo de 10^{-6} entre as duas últimas iterações.

2.2.3 Parametrização da matriz de covariância

As características das distribuições de clusters (orientação, tamanho e forma) variam entre os clusters, enquanto restringem outras a serem as mesmas. Esses novos critérios surgem ao considerar a reparametrização da matriz de covariância Σ_j em termos de sua descrição por autovalores.

$$\Sigma_j = \sigma_j^2 D_j \Lambda_j D_j^T,$$

onde D_j é a matriz de autovetores e Λ_j é uma matriz diagonal com os autovalores de Σ_j. Para $j = 1, 2, \ldots, c$, temos $\sigma_j^2 > 0$, proporcional aos autovalores de Σ_j. Para obter identificabilidade, assume-se que $\mathrm{tr}(\Lambda_j) = 1$. A orientação de componentes principais de Σ_j é determinada por D_j, enquanto Λ_j especifica o tamanho (volume) e a forma do contorno da densidade.

O identificador dos modelos para a parametrização da matriz de covariância é estruturado da seguinte forma:

- Primeira letra: volume entre modelos (E - "Equal", V - "Variable");
- Segunda letra: razão dos volumes entre dimensões entre modelos (I - Isométrico

Tabela 1: Modelos para parametrização da matriz de covariância Σ_j

Identificador	Modelo	Distribuição	Volume	Formato	Orientação
E	Univariada	Igual			
V	Univariada	Variável			
EII	$\sigma^2 I$	Esférica	Igual	Igual	
VII	$\sigma_j^2 I$	Esférica	Variável	Igual	
EEI	$\sigma^2 \Lambda$	Diagonal	Igual	Igual	Alinhado aos eixos
VEI	$\sigma_j^2 \Lambda$	Diagonal	Variável	Igual	Alinhado aos eixos
EVI	$\sigma^2 \Lambda_j$	Diagonal	Igual	Variável	Alinhado aos eixos
VVI	$\sigma_j^2 \Lambda_j$	Diagonal	Variável	Variável	Alinhado aos eixos
EEE	Σ	Elipsoidal	Igual	Igual	Igual
VEE	$\sigma_j^2 D \Lambda D^T$	Elipsoidal	Variável	Igual	Igual
EVE	$\sigma^2 D \Lambda_j D^T$	Elipsoidal	Igual	Variável	Igual
EEV	$\sigma^2 D_j \Lambda D_j^T$	Elipsoidal	Igual	Igual	Variável
VVE	$\sigma_j^2 D \Lambda_j D^T$	Elipsoidal	Variável	Variável	Igual
EVV	$\sigma^2 D_j \Lambda_j D_j^T$	Elipsoidal	Igual	Variável	Variável
VEV	$\sigma_j^2 D_j \Lambda D_j^T$	Elipsoidal	Variável	Igual	Variável
VVV	Σ_j	Elipsoidal	Variável	Variável	Variável

dentro do cluster, E - "Equal" entre clusters, V - Variado entre clusters);

- Terceira letra: orientação dos eixos entre modelos (I - Isométrico ao longo dos eixos, E - "Equal", V - "Variable").

É importante ressaltar que a quantidade de parâmetros a serem estimados varia entre os modelos escolhidos, o que deve ser considerado na seleção desses modelos.

O agrupamento baseado em modelos de mistura nos permite avaliar a incerteza associada à probabilidade de uma determinada observação pertencer a um cluster. Assim, podemos calcular a incerteza associada à alocação da i-ésima observação ao cluster j, que é medida por:

$$\text{Uncer}_i = 1 - \max_{j=1,\ldots,c} \hat{z}_{i,j}. \tag{9}$$

A incerteza para o ponto de dados i, $Uncer_i$, será maior para os pontos de dados i para os quais $\hat{z}_{i,1}, \ldots, \hat{z}_{i,c}$ são iguais entre si, resultando em $\text{Uncer}_i = \frac{1}{G}$ para esses pontos de dados. A incerteza será menor quando um dos $\hat{z}_{i,1}, \ldots, \hat{z}_{i,c}$ estiver próximo de 1.

2.2.4 Determinar número de clusteres e a estrutura da matriz de variância-covariância

Dois problemas básicos que surgem na análise de agrupamento utilizando modelos de mistura gaussiana são a seleção do modelo de parametrização da matriz de variância-covariância e a determinação do número de clusters. Existem compensações entre a escolha do número de clusters e a do modelo de agrupamento. Se um modelo mais simples

for utilizado, pode ser necessário um maior número de clusters para fornecer uma boa representação dos dados. Se um modelo mais complexo for usado, menos clusters podem ser suficientes. Por exemplo, considere a situação em que há um único cluster gaussiano cuja matriz de covariância corresponde a um elipsóide longo e fino. Se um modelo com componentes esféricos de volume igual (o modelo subjacente ao método de Ward e ao k-means) fosse usado para ajustar esses dados, mais de um cluster hiperesférico seria necessário para aproximar o único elipsoide alongado.

Uma abordagem para o problema da seleção de modelos é baseada na seleção bayesiana de modelos, através de fatores de Bayes e probabilidades de modelos posteriores. A ideia básica é que se vários modelos estatísticos, $M_1, \ldots, M_K$, são considerados, com probabilidades a priori $p(M_k)$, para $k = 1, \ldots, K$ (geralmente consideradas iguais), então, pelo teorema de Bayes, a probabilidade posterior do modelo M_k dado os dados D é proporcional à probabilidade dos dados dado o modelo M_k, vezes a probabilidade a priori do modelo, ou seja,

$$p(M_k|D) \propto p(D|M_k)p(M_k)$$

Quando há parâmetros desconhecidos, então, pela lei da probabilidade total, $p(D|M_k)$ é obtida integrando sobre os parâmetros, ou seja,

$$p(D|M_k) = \int p(D|\theta_{M_k}, M_k)p(\theta_{M_k}|M_k)d\theta_{M_k}$$

onde $p(\theta_{M_k}|M_k)$ é a distribuição a priori de θ_{M_k}, o vetor de parâmetros para o modelo M_k. A quantidade $p(D|M_k)$ é conhecida como a verossimilhança integrada, ou verossimilhança marginal, do modelo M_k.

Logo, uma abordagem bayesiana natural para a seleção de modelos é, então, escolher o modelo que é mais provável a posteriori. Se as probabilidades a priori dos modelos, $p(M_k)$, forem as mesmas, isso equivale a escolher o modelo com a maior verossimilhança integrada. A principal dificuldade na utilização dos fatores de Bayes é a avaliação da integral que define a verossimilhança integrada. Para modelos regulares, a verossimilhança integrada pode ser aproximada simplesmente pelo Critério de Informação Bayesiano ou BIC:

$$\mathrm{BIC}_{M_k} = \log p(D|M_k) \approx 2 \log p(D|\hat{\theta}_{M_k}, M_k) - \nu_{M_k} \log(n)$$

onde ν_{M_k} é o número de parâmetros independentes a serem estimados no modelo M_k. Portanto, quanto maior o valor de BIC, melhor o modelo se ajustou aos dados.

Uma possível vantagem adicional para a modelagem de mistura finita nesse contexto é a possibilidade de que esses métodos de seleção de modelos possam ser aplicados simultaneamente para determinar tanto o número de clusters quanto a forma mais apropriada das distribuições componentes na mistura. Ao contrário dos testes baseados em LRT-

testes, os critérios de informação permitem quantificar as diferenças entre um conjunto de modelos candidatos, e pode não haver um único melhor modelo.

Há um outro critério de seleção de modelo, chamado "Integrated Completed Likelihood"(ICL), no qual, o ICL é igual ao BIC penalizado pela entropia esperada da classificação, com a entropia sendo alta quando há grande incerteza sobre a classificação; veja mais detalhes em [2].

2.3 Vantagens e Desvantagens

O modelo de mistura gaussiana apresenta diversas **vantagens**, tais como:

- GMMs podem capturar distribuições de dados que não são esféricas ou homogêneas. Isso significa que eles são eficazes para identificar clusters que podem ter formas variadas e complexas, ao contrário de métodos como o K-means.

- GMMs atribuem a cada observação uma probabilidade de pertencimento a cada cluster, em vez de uma atribuição rígida. Isso permite a identificação de incertezas nas classificações.

- GMMs permitem a inclusão de informações a priori sobre os clusters, como suas formas e tamanhos, o que pode ser útil em contextos onde essa informação é disponível.

- Os resultados de GMMs podem ser interpretados em termos de componentes gaussianos, onde cada componente representa um cluster, assim, as médias e covariâncias fornecem insights sobre a posição e a forma de cada cluster.

Essas vantagens fazem dos GMMs uma abordagem eficaz para tarefas de clusterização, especialmente em cenários onde a incerteza deve ser considerada. Entretanto, possui algumas **desvantagens** em relação a outros métodos de clusterização, tais como:

- Determinar o número ideal de número de clusters pode ser uma tarefa difícil, pois escolher uma quantidade inadequada pode resultar em uma modelagem imprecisa.

- Os Modelos de Mistura Gaussiana demandam recursos computacionais, além de que o algoritmo "EM", empregado para estimar os parâmetros, pode ser lento, principalmente em grandes conjuntos de dados. Além disso, o EM tende a convergir para mínimos locais, dependendo das condições iniciais, o que significa que a qualidade dos resultados pode variar com diferentes inicializações, o que pode levar a um ajuste subótimo [2].

- GMMs podem ser influenciados por outliers, estes que podem afetar as médias e matriz de variância-covariância, distorcendo a modelagem dos clusteres.

- GMMs assumem que os dados em cada cluster seguem uma distribuição normal multivariada. Portanto, se os dados não se ajustarem bem a essa suposição, a performance do modelo é comprometida.

- Embora GMMs sejam aplicáveis a dados de alta dimensão, a interpertação dos resultados pode se tornar complicada, visto que a visualização e compreensão das distribuições gaussianas em várias dimensões se torna díficil.

Essas desvantagens devem ser consideradas ao decidir se GMMs são a melhor abordagem para um problema específico de clusterização. Em algumas situações, métodos alternativos, como k-means e clustering hierárquico, podem ser mais eficazes.

3 Aplicação

3.1 Análise Descritiva

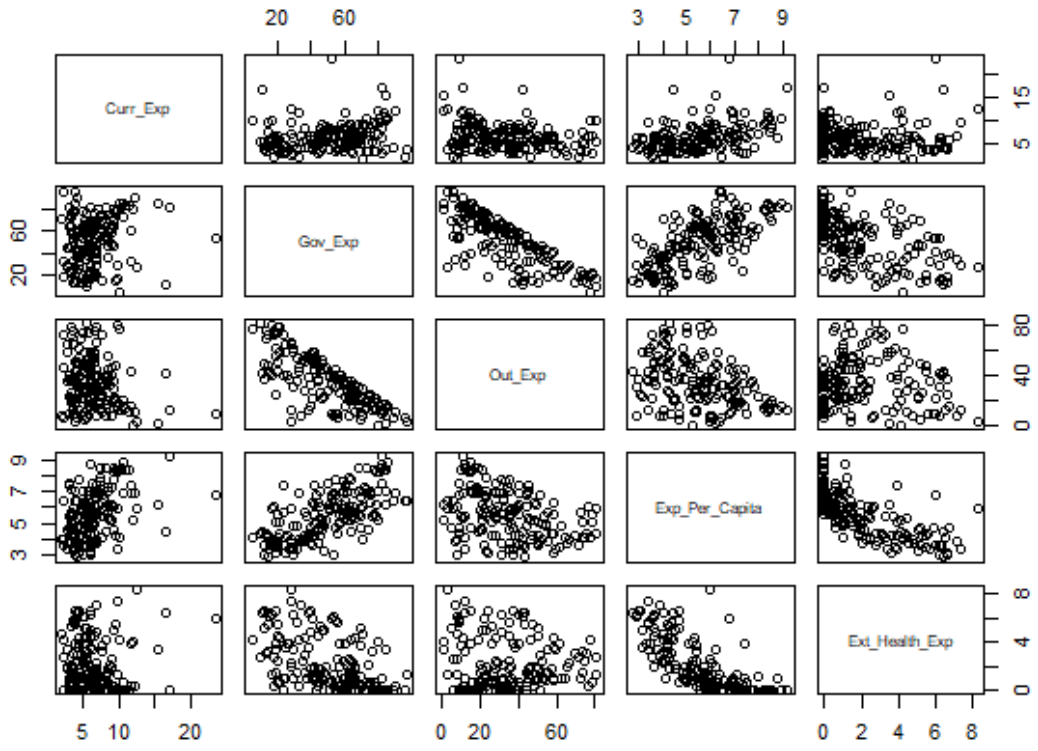


Figura 1: Matriz de Scatterplots entre as variáveis

É importante ressaltar que a transformação logarítmica foi aplicada à variável "Exp_Per_Capita", enquanto a variável "Ext_Health_Exp"passou por uma transformação de raiz quadrada. Essas transformações visam melhorar o agrupamento, diminuindo os

efeitos de possíveis outliers e facilitando a identificação de diferentes clusters, como observado na Figura 1. Ao observar a Figura 1, notamos a presença de elipses que sugerem a existência de dois clusters, além de alguns possíveis outliers. Também é evidente uma correlação considerável entre as variáveis, especialmente entre "Gov_Exp"e "Out_Exp".

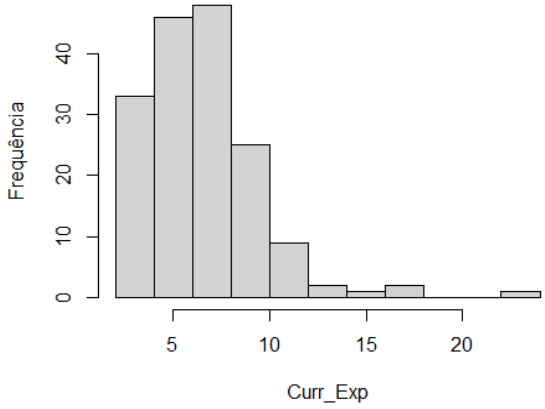


Figura 2: Histograma da variável Curr_Exp

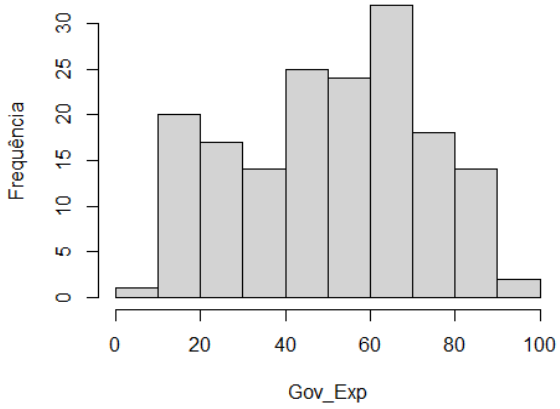


Figura 3: Histograma da variável Gov_Exp

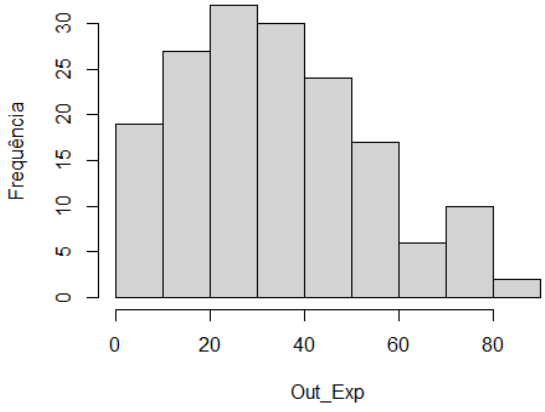


Figura 4: Histograma da variável Out_Exp

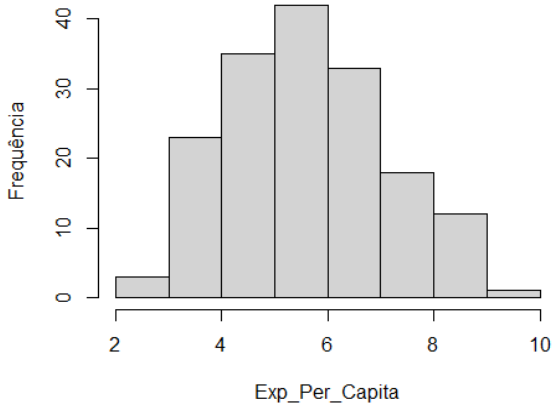


Figura 5: Histograma da variável Exp_Per_Capita

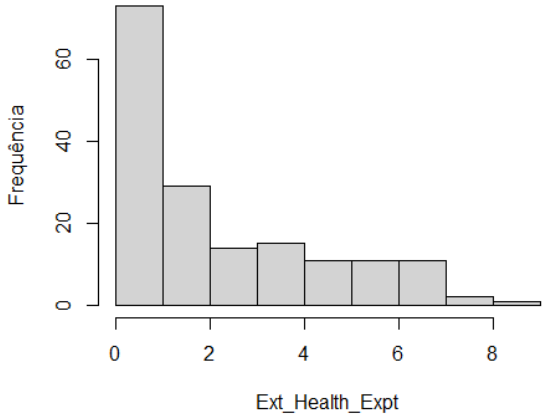


Figura 6: Histograma da variável Ext_Health_Exp

Ao observar a Figura 3, é evidente a presença de duas modas, o que sugere a existência de dois possíveis clusters. Por outro lado, ao analisar as Figuras 2 a 6, com exceção da Figura 3, notamos a presença de uma única moda, acompanhada de alguns outliers, o que pode indicar a ausência de mais de um cluster.

3.2 Clusterização através do Modelo de Mistura Gaussiana(GMM)

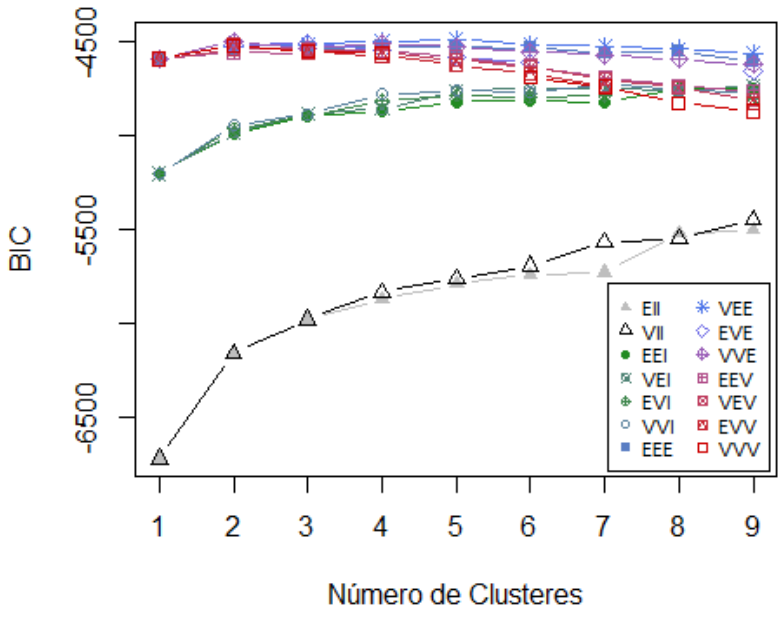


Figura 7: Gráfico com os valor BIC para a seleção de modelo de parametrização de Σ

Analisando a Figura 7, percebemos que número ótimo de clusteres é 2 ou 3, escolhendo os modelos exceto EII, VII, EEI, VEI, VVI, EVI. Portanto, o modelo a ser escolhido para a parametrização das matriz de variância-covariância é VVE com 2 clusteres

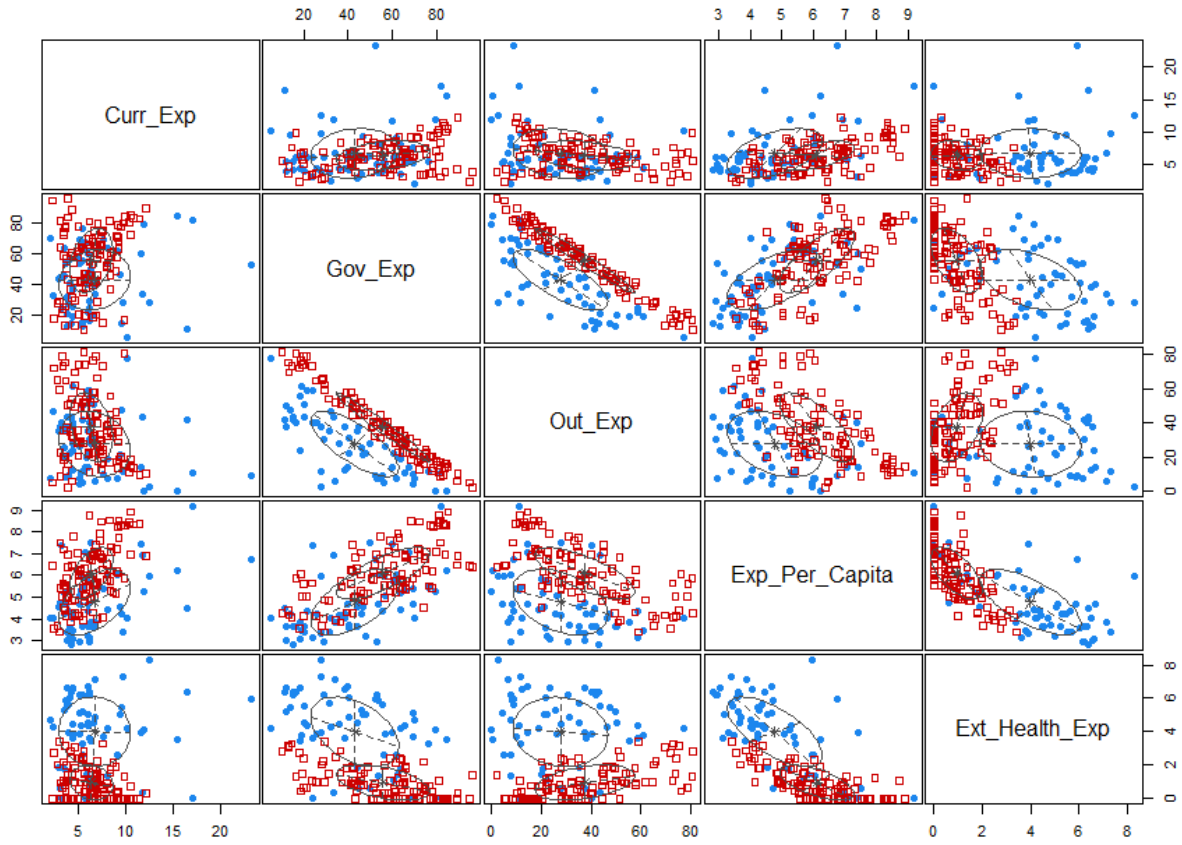


Figura 8: Matriz de Scatterplots entre as variáveis com os respectivos clusteres pertencentes

Na Figura 8, observamos as elipses calculadas em relação às respectivas observações, evidenciando a diferença entre os dois clusters na maioria das variáveis. Contudo, a presença de outliers distorce a forma das elipses. Essa distinção é mais claramente ilustrada na Figura 9, que destaca um grupo de países (cluster 2) com maiores gastos na área da saúde, tanto por fontes governamentais quanto por fontes privadas, que também investem mais per capita. É importante notar que o cluster 1 apresenta valores mais altos de gastos com saúde financiados por fontes externas em comparação ao cluster 2, além de gastar igual ao outro cluster em relação a porcentagem do PIB. Vale ressaltar que o Brasil faz parte do cluster 1, apresentando menores gastos com saúde.

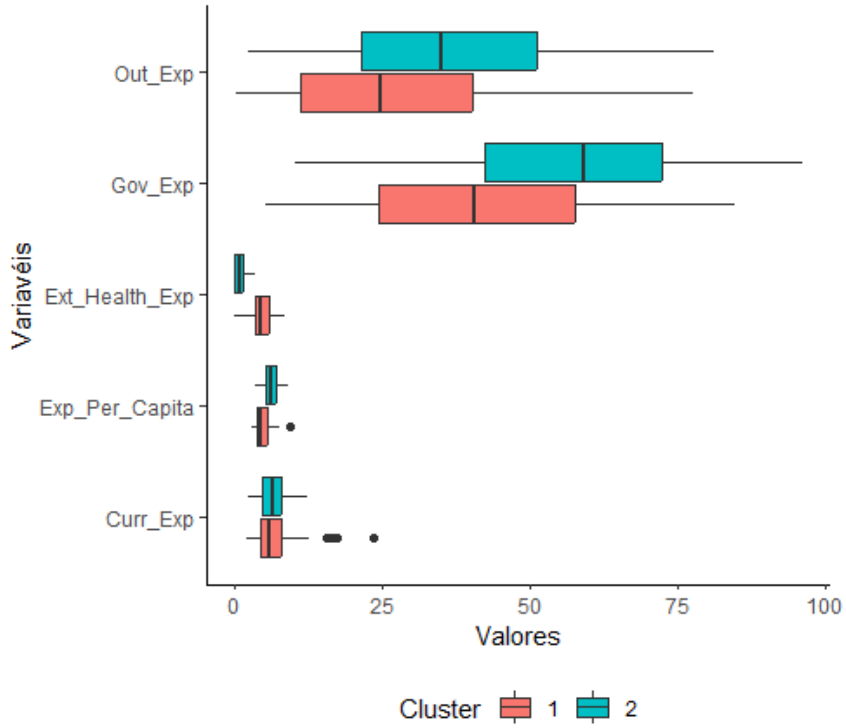


Figura 9: Boxplot de cada cluster calculado pelo GMM para cada variável

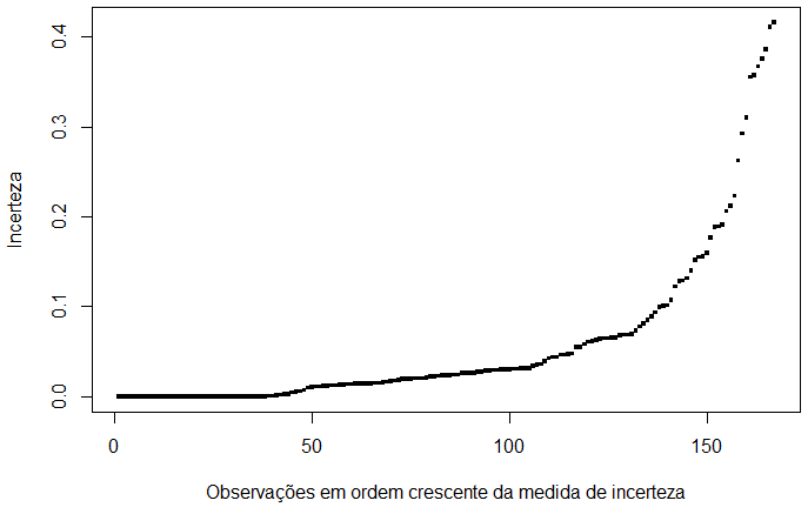


Figura 10: Gráfico da incerteza das observações

Ao analisarmos a incerteza das observações em relação aos clusters na Figura 10, observamos que a maioria delas apresenta uma incerteza inferior a 0,1, com apenas 29 das 167 observações exibindo incerteza superior a 0,1. Assim, podemos concluir que a técnica utilizada para o agrupamento é razoável.

4 Conclusão

Portanto, a presença de dois clusters sugere que a classificação entre países desenvolvidos e subdesenvolvidos se mantém em relação aos gastos com saúde, mas, entre países que mais investem na saúde e países que menos investem. Assim, é crucial que o Brasil se esforce para se integrar ao cluster em que é composto por países com maiores investimentos nessa área, afim de obter índices futuros sobre a qualidade da saúde no país melhores, representando uma melhora nessa área para a população. Contudo, não podemos afirmar que um aumento nos gastos em saúde resulta diretamente em uma melhoria na qualidade da saúde da população. Procurar estudos já realizados sobre a relação entre gastos em saúde e qualidade da saúde pode auxiliar a enteder melhor essa relação. Além disso, é importante que o investimento nessa área seja realizado de maneira eficaz.

Uma possível melhoria na abordagem de clusterização seria permitir a inclusão de observações que não seguem a distribuição assumida, como outliers e outros pontos de "ruído". Isso poderia resultar em uma análise mais robusta e, possivelmente, alterar o resultado final. Esses pontos são considerados ao assumir que eles derivam de um processo de Poisson, modificando a função de verossimilhança de acordo com essa premissa (mais detalhes em [2]).

5 Referências

[1]Dempster, A. P., et al. "Maximum Likelihood from Incomplete Data via the EM Algorithm." Journal of the Royal Statistical Society. Series B (Methodological), vol. 39, no. 1, 1977, pp. 1–38. JSTOR, `http://www.jstor.org/stable/2984875`. Acesso em 24 de Setembro de 2024.

[2]Bouveyron, Charles, Gilles Celeux, T Brendan Murphy, e Adrian E Raftery. 2019. Model-Based Clustering and Classification for Data Science: With Applications in R. Cambridge University Press.

[3]Everitt, Brian S, Sabine Landau, Morven Leese, and Daniel Stahl. 2011. Cluster Analysis, 5th Edition. John Wiley & Sons.

[4]Johnson, Richard A, and Dean W Wichern. 2007. Applied Multivariate Statistical Analysis, 6th Edition. Prentice-Hall.

[5] World Bank Group. Disponível em: `https://www.worldbank.org/en/home`. Acesso em 26 de Setembro de 2024.